ШВИДКИЙ СТАРТ • ПРАКТИЧНИЙ ПОСІБНИК

Лабораторна робота №2

Запуск vLLM на MacBook Pro M3 Max

> Інструкція для MacBook Pro M3 Max. Потрібно запустити мовну модель локально, підключити до неї Python-програму `cli.py` та продемонструвати роботу через Terminal.
>
> Для цього використовуватимуться два вікна Terminal: в одному працюватиме сервер vLLM, в іншому — Python CLI.

КРОК 1 Встановлення vLLM-Metal

Для запуску vLLM на MacBook з Apple Silicon використовується vLLM-Metal.

У Terminal послідовно виконай:

TERMINAL `brew tap`

```
brew tap vllm-project/vllm-metal https://github.com/vllm-project/vllm-metal
```

TERMINAL `brew install`

```
brew install vllm-project/vllm-metal/vllm-metal
```

Після завершення встановлення перевір, чи доступна команда:

TERMINAL `перевірка версії`

```
vllm --version
```

Якщо версія відображається, можна переходити до запуску моделі.

> *Команди підготовлені для macOS, але на конкретному MacBook ще не перевірялися.*

КРОК 2 Завантаження та запуск мовної моделі

Для лабораторної обрано модель `Qwen/Qwen2.5-1.5B-Instruct-AWQ`, яка має менше ніж 3 мільярди параметрів.

Введи:

TERMINAL 1 (СЕРВЕР VLLM) `vllm serve`

```
vllm serve Qwen/Qwen2.5-1.5B-Instruct-AWQ \
  --port 8000 \
  --max-model-len 2048 \
  --gpu-memory-utilization 0.50
```

Під час першого запуску vLLM завантажить модель із Hugging Face, після чого запустить локальний API-сервер на порту `8000`.

Завантаження може зайняти кілька хвилин. Дочекайся повідомлення про готовність сервера.

> **Це вікно Terminal залиш відкритим.** Сервер повинен працювати протягом усієї демонстрації.

> Якщо vLLM повідомляє про несумісність моделі, спочатку потрібно підібрати підтримуваний checkpoint. Цю конфігурацію ще не перевірено на M3 Max.

КРОК 3 Перевірка роботи сервера

Відкрий друге вікно Terminal і виконай:

TERMINAL 2 (КЛІЄНТ) `curl GET /v1/models`

```
curl http://127.0.0.1:8000/v1/models
```

У відповіді має з'явитися JSON з інформацією про завантажену модель. Знайди поле `id`, наприклад:

ОЧІКУВАНИЙ ФРАГМЕНТ ВІДПОВІДІ JSON `JSON`

```
"id": "Qwen/Qwen2.5-1.5B-Instruct-AWQ"
```

Цей ідентифікатор потрібно використовувати під час запуску `cli.py`.

> Якщо виникає `Connection refused`, перевір, чи завершилося завантаження моделі в першому Terminal.

КРОК 4 Підготовка Python CLI

Для лабораторної тобі передадуть два файли:

- `cli.py` — програма для надсилання запитань моделі через API.
- `requirements.txt` — залежності Python.

Розмісти їх у папці `lab2_vllm` на робочому столі.

У другому Terminal перейди до цієї папки:

TERMINAL 2 `перехід до каталогу`

```
cd ~/Desktop/lab2_vllm
```

Створи та активуй віртуальне середовище:

TERMINAL 2 `створення та активація venv`

```
python3 -m venv .venv
source .venv/bin/activate
```

Встанови залежності:

TERMINAL 2 `pip install`

```
python -m pip install -r requirements.txt
```

Це початкове налаштування. Під час наступних запусків достатньо перейти до папки й активувати `.venv`.

КРОК 5 Запуск CLI та перевірка діалогу

У другому Terminal запусти:

TERMINAL 2 `запуск cli.py`

```
python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ
```

Після підключення до сервера з'явиться запрошення `You:`.

Введи перше запитання:

> **ВВЕДЕННЯ ЗАПИТАННЯ (YOU):**
> `What is machine learning? Explain in two sentences.`

Дочекайся відповіді та постав друге:

> **ВВЕДЕННЯ ЗАПИТАННЯ (YOU):**
> `Give me one real-world example of it.`

Друге запитання пов'язане з першим. Так можна перевірити, чи програма передає моделі історію розмови.

Для завершення введи:

TERMINAL 2 `вихід з діалогу`

```
exit
```

Після виходу діалог автоматично збережеться у папці `outputs/dialogs` у форматі Markdown.

КРОК 6 Експерименти з параметрами генерації

Для лабораторної потрібно продемонструвати, як змінюється поведінка моделі залежно від параметрів.

6.1. System prompt

System prompt задає інструкцію щодо стилю або правил відповіді.

Запусти:

TERMINAL 2 `--system-prompt`

```
python cli.py \
  --model Qwen/Qwen2.5-1.5B-Instruct-AWQ \
  --system-prompt "You are a machine learning teacher. Explain concepts in simple English."
```

Постав запитання:

> **ВВЕДЕННЯ ЗАПИТАННЯ (YOU):**
> `What is overfitting?`

Перевір, чи модель дотримується заданого стилю. Заверши діалог через `exit`.

6.2. Temperature

Temperature регулює випадковість генерації: нижчі значення зазвичай дають більш передбачувані відповіді, вищі — різноманітніші.

Спочатку запусти:

TERMINAL 2 `temperature = 0.2`

```
python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ --temperature 0.2
```

Постав запитання:

> **ВВЕДЕННЯ ЗАПИТАННЯ (YOU):**
> `Suggest three names for an AI assistant for students.`

Заверши діалог і повторно запусти програму:

TERMINAL 2 `temperature = 1.2`

```
python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ --temperature 1.2
```

Постав **те саме запитання**.

Порівняй результати. Вища temperature може дати незвичнішу відповідь, хоча це не гарантується для кожного запиту.

6.3. Max tokens

`max_tokens` обмежує максимальну кількість токенів у згенерованій відповіді.

Спочатку:

TERMINAL 2 `max-tokens = 30`

```
python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ --max-tokens 30
```

Питання:

> **ВВЕДЕННЯ ЗАПИТАННЯ (YOU):**
> `Explain five advantages of machine learning.`

Потім:

TERMINAL 2 `max-tokens = 200`

```
python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ --max-tokens 200
```

Повтори те саме питання.

Порівняй довжину відповідей. За меншого ліміту модель може не встигнути завершити пояснення.

КРОК 7 Демонстрація викладачу

Під час захисту потрібно показати:

1. Запущений сервер vLLM у першому Terminal.
2. Перевірку моделі командою `curl http://127.0.0.1:8000/v1/models`.
3. Запуск `cli.py` у другому Terminal.
4. Два послідовні запитання, щоб показати роботу моделі та збереження контексту.
5. Повторний запуск із `--system-prompt`, `--temperature` або `--max-tokens`.
6. Файли збережених діалогів у `outputs/dialogs`.

ФІНАЛ Завершення роботи

Після демонстрації введи `exit` у Python CLI.

Потім повернися до першого Terminal і натисни `Ctrl + C`, щоб зупинити сервер vLLM.

Підсумок виконання

Результат: локально запущена мовна модель, працюючий Python CLI, експерименти з параметрами генерації та збережені діалоги.

ПАМ'ЯТКА Зведені команди та параметри

ЕТАП / ТЕРМІНАЛ	КОМАНДА	ПРИЗНАЧЕННЯ
Terminal 1 (Сервер)	`vllm serve Qwen/Qwen2.5-1.5B-Instruct-AWQ \ --port 8000 --max-model-len 2048 --gpu-memory-utilization 0.50`	Локальний запуск vLLM API
Terminal 2 (Перевірка)	`curl http://127.0.0.1:8000/v1/models`	Перевірка готовності API
Terminal 2 (Базовий запуск)	`python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ`	Діалог зі збереженням контексту
Terminal 2 (Стиль відповіді)	`python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ \ --system-prompt "You are a machine learning teacher. Explain concepts in simple English."`	Завдання інструкції стилю
Terminal 2 (Випадковість)	`python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ --temperature 0.2` (та `1.2`)	Порівняння варіативності відповідей
Terminal 2 (Ліміт довжини)	`python cli.py --model Qwen/Qwen2.5-1.5B-Instruct-AWQ --max-tokens 30` (та `200`)	Порівняння довжини генерації
Зупинка процесів	`exit` (у CLI) / `Ctrl + C` (у Terminal 1)	Коректне завершення роботи